Johan Hernández

AI Engineer · Solutions Architect

Medellín, Colombia · +57 321 296 6104 · jshernandezo97@gmail.com
linkedin.com/in/johan-ai-solutions-architect · kmaleon.co

PERFIL PROFESIONAL

AI Engineer enfocado en llevar sistemas de IA desde el prompt hasta producción. 8+ años de ingeniería de software más 1.5+ años construyendo soluciones LLM en producción: pipelines de análisis con Anthropic Claude, agentes conversacionales de voz (Vapi + ElevenLabs + Twilio), sistemas multi-agente orquestados, y workflows de automatización con n8n. Actualmente fundador y único ingeniero de Kmaleon (kmaleon.co), SaaS B2C con IA para 17 países de LATAM, operado por un equipo de 6 agentes de Claude Code en GitHub Issues. Mi diferenciador: la mayoría de AI engineers entregan APIs, prototipos o notebooks. Yo entrego producto completo — UI usable, deployed, monitoreado, con métricas reales.

STACK TECNOLÓGICO

IA & LLMs (Primary) Anthropic Claude (SDK directo) · OpenAI API · Claude Code · Prompt Engineering · Sistemas Multi-Agente · Agentic Workflows · LLM Pipelines en Producción · Semantic Matching

AI Conversacional Vapi · ElevenLabs · Twilio · WhatsApp Cloud API · Voice-to-Text / Text-to-Speech · Agentes de voz multi-turno

Automatización & Orquestaciónn8n (workflows productivos) · GitHub Issues (orquestación de agentes) · BullMQ + Redis (jobs asíncronos) · Event-driven design

Lenguajes TypeScript (experto) · JavaScript / Node.js (experto) · Python (intermedio: scripting, prototipado ML, integraciones API) · Bash · SQL

Backend & Arquitectura NestJS · Node.js · REST APIs · Microservicios · Modular Monolith · MongoDB Atlas · PostgreSQL · Patrones SOA

MLOps & Cloud Docker · Azure DevOps (Boards, Pipelines, YAML CI/CD) · GitHub Actions · CI/CD · AWS (S3, CloudFront, Lambda) · Railway · Cloudflare Pages · Linux

Frontend (Supporting) React 18 · Angular · TypeScript · Tailwind CSS — para entregar productos completos

EXPERIENCIA PROFESIONAL

AI Engineer & Fundador — Kmaleon (kmaleon.co)

Mayo 2024 – Presente · Medellín, Colombia / Remoto

Plataforma SaaS B2C con IA para búsqueda y optimización de empleo, presencia en 17 países de LATAM (pre-launch). Arquitectura end-to-end con foco en pipelines LLM productivos.

- Diseñé e implementé un pipeline de análisis ATS de CVs usando Anthropic Claude: extracción de keywords, scoring de match perfil-vacante, y generación de recomendaciones contextualizadas con manejo language-aware (ES/EN) y preservación del idioma origen del job description.
- Construí un sistema de optimización de CV adaptado a vacantes específicas: el LLM analiza la oferta, identifica gaps y reescribe secciones del CV para maximizar match — con preservación de hechos verificables y prevención de alucinaciones vía prompt structuring.
- Implementé semantic matching entre perfiles de usuario y vacantes agregadas desde 5 fuentes externas (JSearch, RemoteOK, Remotive, TheMuse, Computrabajo) cubriendo 17 países LATAM.
- Orquesté un sistema multi-agente de 6 agentes de Claude Code con roles definidos (Director, Arquitecto, Frontend, Backend, Database, DevOps) coordinados vía GitHub Issues — workflow completo de planeación, implementación, code review y deploy con human-in-the-loop en decisiones irreversibles.
- Producción operativa: NestJS + MongoDB Atlas + BullMQ + Redis en Railway, frontend React en Cloudflare Pages, observabilidad con Winston + correlation IDs, manejo de rate limits y caching de respuestas LLM para optimizar costos de API.

AI Solutions Architect — Proyectos Independientes — Clientes Directos
Mayo 2024 – Presente · Remoto

- Sistema multi-agente de voz para Planet Entertainment (Vapi + ElevenLabs + Twilio): automatización completa de agendamiento de citas y follow-ups con clientes. Reducción estimada del 70% en tiempo de manejo manual de llamadas.
- Workflows de automatización con n8n integrando recolección de datos CRM, validación OTP, y bridging entre canales WhatsApp y voz en un microservicio reutilizable — setup de nuevos clientes pasó de días a horas.
- Agente autónomo de matching y análisis de vacantes (Claude Code + TypeScript + Node.js): sistema multi-agente que busca oportunidades, califica matches semánticamente y genera reportes estructurados sin intervención manual.
- Despliegue de MVPs IA en infraestructura VPS (Docker / Linux): ciclo completo desde prompt engineering y diseño de agente hasta deploy containerizado en producción.

Senior Frontend Engineer · Tech Lead — Rapicredit (Fintech)
Feb 2023 – Abr 2025 · Bogotá, Colombia / Remoto

- Lideré la modernización completa del frontend de la plataforma flagship de Rapicredit en 4 semanas, dirigiendo un equipo de 4 personas — entrega a tiempo, zero downtime en producción.
- Establecí estándares de arquitectura escalable: librerías de componentes, pipelines CI/CD con Azure DevOps (Boards para planeación, Pipelines YAML para builds y deploys del frontend), despliegue en AWS (S3 + CloudFront) y patrones TypeScript-first.
- Gané 2do lugar en la feria de innovación interna con "Sessionless Payments" — flujo de liquidación de créditos sin login usando solo ID + OTP.

Ingeniero Frontend / Software — Klym · IAS Software · Capgemini · iGerencia
Oct 2018 – Ene 2023 · Medellín / Bogotá, Colombia

- 5+ años construyendo aplicaciones full-stack y frontend para clientes enterprise (Bancolombia, Emtelco, fintechs). Liderazgo de equipos de hasta 8 desarrolladores, code reviews, arquitectura limpia, adopción de TypeScript.
- Capgemini (Emtelco): implementé logging custom y monitoreo de KPIs que contribuyeron a una mejora del 15% en estabilidad de la aplicación — fundamentos de observabilidad transferibles a MLOps.

PROYECTOS DESTACADOS DE IA

Pipeline de Análisis ATS con LLM — Kmaleon. Sistema productivo de análisis de CVs vs job descriptions usando Anthropic Claude: extracción de keywords, scoring de compatibilidad, y recomendaciones accionables. Maneja idioma origen del job description y output language preference del usuario.

Sistema Multi-Agente de Voz — Planet Entertainment. Orquestación de agentes conversacionales de voz (Vapi + ElevenLabs + Twilio) con manejo multi-turno, integración con CRM y handoff a agente humano. Backend Node.js, deployed en Docker.

Sistema Multi-Agente de Desarrollo (Claude Code). Workflow de 6 agentes (Director, Arquitecto, Frontend, Backend, Database, DevOps) coordinados vía GitHub Issues. Cada agente opera con contexto curado (CLAUDE.md) y sigue protocolo investigar → reportar → aprobar → implementar — entrega disciplinada sin equipo humano.

Microservicio de Automatización WhatsApp ↔ Voz. Workflow n8n con backend Node.js para integrar CRM, validación OTP, y bridging entre canales — reduce onboarding de clientes nuevos de días a horas.

EDUCACIÓN & CERTIFICACIONES

Ingeniería de Software — Politécnico Grancolombiano, 2021
Tecnólogo en Análisis y Desarrollo de Sistemas de Información — SENA, 2016
Scrum Foundation Professional Certificate — CertiProf, 2020
Inglés Profesional — 1 año de inmersión en Australia · Aprendizaje continuo

Idiomas: Español (Nativo) · Inglés (Intermedio-Avanzado técnico, lectura y comunicación profesional)